Matriz de Costos y Justificación de Modelos

Tarea en el Flujo	Modelo Utilizado	Justificación	Ahorro Estimado
Generación de Contenido y Razonamiento (Agente de IA)	Groq	Se selecciona Groq por su alta velocidad de inferencia (procesamiento ultrarrápido por hardware LPU) y su gran capacidad de razonamiento contextual para conectar las ideas con el RAG de vinos sin latencias molestas en el flujo.	Ahorro de hasta 85% en costos de API por token frente a modelos comerciales equivalentes de alta gama en OpenAI o Anthropic, manteniendo una velocidad de respuesta superior a 300 tokens por segundo.
Indexación y Recuperación de Conocimiento (RAG Vectorial)	Google Gemini Embeddings	Utilizado en la tienda de vectores de n8n para transformar los bloques de texto de vinos de Salta, Mendoza y San Juan en vectores semánticos de alta precisión.	Costo operativo mínimo o integrado, ya que aprovecha las cuotas optimizadas de la infraestructura de embeddings de Google, reduciendo a cero el costo de licencias de bases de datos vectoriales dedicadas (como Pinecone).
Estructuración y Salta de Datos (Output Parser)	Structured Output Parser nativo de n8n	Garantiza que la respuesta del LLM se convierta de forma estricta en un objeto JSON válido (id y borrador) antes de actualizar Airtable, evitando errores de formato que rompan la automatización.	Ahorro de horas de desarrollo y mantenimiento técnico: evita la necesidad de escribir scripts personalizados en JavaScript o Python para limpiar respuestas de texto desestructuradas.

Resumen de Eficiencia del Stack

- **Optimización de Recursos:** Al utilizar Groq para el procesamiento de lenguaje y Gemini Embeddings para la vectorización, se logra un rendimiento de nivel empresarial con un costo por ejecución fraccional (centavos de dólar por mes).
- **Escalabilidad sin Fricciones:** La combinación de Airtable como base operativa y n8n como motor de orquestación permite procesar decenas de ideas de manera totalmente desatendida, interviniendo únicamente en el punto de control humano (*Human-in-the-loop*) en Slack.